

Detekcja Gwiazd Pulsarowych za pomocą sieci MLP

Antoni Ciągała
Jan Marek

7 maja 2026

Plan prezentacji

- 1 Kontekst i cel projektu
- 2 Dane i preprocessing
- 3 Architektura modelu
- 4 Trening i wyniki

Czym są pulsary?

- Pulsary to **gwiazdy neutronowe** emitujące regularne impulsy radiowe wykrywalne na Ziemi
- Służą jako sondy czasoprzestrzeni i ośrodka międzygwiazdowego
- Teleskopy generują **petabajty danych** – ręczna analiza jest niemożliwa
- Automatyczna klasyfikacja za pomocą ML jest standardem w radioastronomii

Cel: binarna klasyfikacja sygnałów – pulsar (1) vs. szum (0),
przy silnej nierównowadze klas ($\sim 9\%$ pulsarów)



Rysunek: Pulsar Kraba (NASA)

Cechy (8 zmiennych ciągłych):

Zintegrowany profil impulsu:

- Średnia, Odchylenie std.
- Kurtoza, Skośność

Krzywa DM-SNR:

- Średnia, Odchylenie std.
- Kurtoza, Skośność

Rozkład klas:

Klasa	Liczba	Udział
Szum (0)	11 375	90.8%
Pulsar (1)	1 153	9.2%
Razem	12 528	100%

Braki danych:

- Kurtoza profilu: 1 735
- Odch. std. DM-SNR: 1 178
- Skośność DM-SNR: 625

Struktura warstw:


$8 \xrightarrow{\text{FC}} 64 \xrightarrow{\text{FC}} 64 \xrightarrow{\text{FC}} 1$

Każda warstwa ukryta:

- **Linear** → **BatchNorm1d** → **ReLU** → **Dropout**

Warstwa wyjściowa: pojedynczy **logit** (bez sigmoid)

Hiperparametr	Wartość
Rozmiary warstw	[64, 64]
Dropout	0.3
Inicjalizacja	Kaiming (He)
Optymalizator	Adam
Learning rate	10^{-3}
Weight decay	10^{-4}
Batch size	64
Early stopping	patience = 100
Monitorowana met.	f1



- Model zbiega szybko – brak przeuczenia ($\text{val loss} < \text{train loss}$)

Metryki ewaluacyjne – dlaczego nie tylko dokładność?

Problem z Accuracy

Przy 9% pulsarów model przewidujący zawsze szum osiąga Accuracy = 91% – bez odkrycia ani jednego pulsara. Accuracy jest niewystarczającą metryką przy nierównowadze klas.

$$\text{Recall (czułość)} = \frac{TP}{TP + FN}$$

Ile prawdziwych pulsarów model wykrył?

$$\text{Precision (precyzja)} = \frac{TP}{TP + FP}$$

Ile spośród przewidzianych pulsarów to prawdziwe pulsary?


$$\text{F1-Score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Średnia harmoniczna precyzji i czułości. Wysoka wartość wymaga, żeby obie były dobre jednocześnie.


ROC-AUC

Mierzy zdolność modelu do rozróżniania klas niezależnie od progu. AUC = 1.0 oznacza idealne rozdzielanie; AUC = 0.5 to losowe zgadywanie.

Metryki walidacyjne w czasie treningu




Macierz pomyłek



Wyniki na zbiorze val

Metryka	Wartość
F1	0.9124
Precision	0.9486
Recall	0.8788
ROC-AUC	0.9869

- **FP = 11** – fałszywe alarmy
- **FN = 28** – przeoczone pulsary



Interpretacja

AUC = 0.9869 oznacza, że model z 98.7% prawdopodobieństwem przypisze wyższy score prawdziwemu pulsarowi niż szumowi

- Optymalny próg: ≈ 0.56

Dziękujemy za uwagę

Kod źródłowy projektu:

`github.com/aciagala/pulsar-detection`